
Département : *Informatique, Réseaux et Télécommunications (IRT)*
Filière : *Génie Aéronautique et Technologies de l'Espace (GATE)*
Niveau : *5ème année*
Année universitaire : *2025/2026*

Rapport du devoir libre

Sujet :

MAINTENANCE PRÉdictive DANS L'AÉRONAUTIQUE PAR IA

Réalisé par :

- Al-Mahaidou Ben
Soulaimana

Encadre par :

- Pr. BENTAJER Ahmed

Table des matières :

1. Introduction : **Erreur ! Signet non défini.**
2. Objectifs du TP : **Erreur ! Signet non défini.**
3. Généralité sur MCC : **Erreur ! Signet non défini.**
4. Principe de fonctionnement du moteur à courant continu : **Erreur ! Signet non défini.**
5. Matlab Simulink : **Erreur ! Signet non défini.**
 - 5.1. Qu'est-ce que c'est Matlab Simulink ? **Erreur ! Signet non défini.**
 - 5.2. Création d'un modèle Simulink : **Erreur ! Signet non défini.**
 - 5.3. Bibliothèques et Blocs Simulink : **Erreur ! Signet non défini.**
 - 5.4. Composants clés de la Bibliothèque Électrique : .. **Erreur ! Signet non défini.**
6. Les équations électriques et mécaniques l'un moteur à Courant Continu : **Erreur ! Signet non défini.**
7. Manipulation : **Erreur ! Signet non défini.**
 - 7.1 Etude en boucle ouverte du moteur DC :.. **Erreur ! Signet non défini.**
 - 7.2 Commande en vitesse d'un moteur DC :.. **Erreur ! Signet non défini.**
8. Conclusion : **Erreur ! Signet non défini.**

<https://github.com/almahaidoubensoula-dev/Devoir-libre-Maintenance-ave-AI>

Introduction :

Contexte Industriel et Enjeux Économiques :

L'industrie aéronautique moderne est caractérisée par des exigences de sécurité absolue, une forte pression économique et une compétitivité accrue. Les principaux acteurs tels qu'Airbus, Boeing, Safran et General Electric (GE) doivent constamment optimiser leurs opérations de maintenance, qui représentent jusqu'à 20-30% des coûts d'exploitation totaux d'une compagnie aérienne. Dans ce contexte, la fiabilité des turboréacteurs, composants critiques des aéronefs, est primordiale. Toute défaillance peut avoir des conséquences catastrophiques sur la sécurité, la ponctualité des vols et la rentabilité économique.

Problématique des Stratégies de Maintenance Traditionnelles :

Traditionnellement, deux approches principales dominent :

- **Maintenance Corrective** : Intervention après la panne. Inacceptable en aéronautique pour des raisons évidentes de sécurité.
- **Maintenance Préventive** : Remplacement systématique de composants selon un calendrier fixe. Cette approche, bien que sécuritaire, est extrêmement coûteuse car elle conduit souvent à remplacer des pièces encore parfaitement fonctionnelles, générant un gaspillage de ressources et des immobilisations inutiles des appareils.

Émergence de la Maintenance 4.0 par l'Intelligence Artificielle :

La Maintenance Prédictive émerge comme le paradigme de la Maintenance 4.0. Son principe fondateur est d'utiliser les données massives générées par les capteurs embarqués (Internet des Objets Industriels - IIoT) pour surveiller l'état de santé des équipements en temps réel. En appliquant des algorithmes d'Intelligence Artificielle (IA) et de Machine Learning (ML) à ces données, il devient possible de détecter des signes précurseurs de défaillance et d'estimer la **Durée de Vie Restante (RUL - Remaining Useful Life)**. L'objectif est d'intervenir "juste à temps", maximisant ainsi l'utilisation des composants tout en garantissant la sécurité et en réduisant significativement les coûts de maintenance. Ce projet se situe au cœur de cette révolution technologique.

Objectifs du Projet :

Objectif Principal : Estimation de la RUL (Remaining Useful Life) :

L'objectif central de ce projet est de développer un pipeline complet de Data Science permettant de prédire la durée de vie restante d'un turboréacteur. À partir des données brutes de ses capteurs (températures, pressions, vitesses de rotation, etc.), l'algorithme doit fournir une estimation quantitative (en nombre de cycles opérationnels) du temps restant avant une défaillance nécessitant une maintenance.

Objectifs Spécifiques et Méthodologiques 2.3 Livrables Attendus :

Acquisition et Compréhension des Données : Maîtriser le jeu de données NASA C-MAPSS, standard de référence dans la recherche en maintenance prédictive.

Analyse Exploratoire (EDA) : Identifier les capteurs pertinents, visualiser les patterns de dégradation et comprendre les relations physiques sous-jacentes.

Ingénierie des Features : Construire la variable cible (RUL) et préparer les données pour l'apprentissage automatique (nettoyage, sélection, normalisation).

Modélisation ML : Implémenter, entraîner et comparer au moins deux algorithmes de régression : un modèle simple de référence et un modèle plus performant.

Évaluation Rigoureuse : Valider les modèles sur des données de test indépendantes et interpréter les résultats à l'aide de métriques pertinentes (RMSE).

Livrables Attendus :

Un Notebook Python/Jupyter exécutable et documenté : Contenant l'ensemble du code, structuré selon les phases du projet et abondamment commenté pour expliquer les choix méthodologiques.

Un Rapport Technique (ce document) : Synthétisant la démarche, les résultats obtenus, et incluant une réflexion critique sur la fiabilité et le potentiel de déploiement industriel de la solution développée.

Généralités sur la Maintenance Prédictive et l'IA :

Définition et Principes de la Maintenance Prédictive :

La maintenance prédictive est une stratégie proactive qui vise à déterminer l'état d'un équipement afin d'estimer le moment optimal pour effectuer une intervention. Contrairement aux approches préventives calendaires, elle se base sur la **surveillance conditionnelle** et l'analyse des signes précurseurs de défaillance. Le processus repose sur trois piliers fondamentaux : l'acquisition de données via des capteurs, l'analyse de ces données (souvent en temps réel), et la prise de décision basée sur l'état de santé prédit. L'objectif ultime est de passer d'une logique de maintenance "à intervalle fixe" ou "après panne" à une logique de maintenance "selon besoin", optimisant ainsi la disponibilité et la rentabilité des actifs.

Apport de l'IA et du Machine Learning dans le Diagnostic Prédictif :

L'Intelligence Artificielle, et plus particulièrement le Machine Learning (ML), est le moteur analytique de la maintenance prédictive moderne. Les algorithmes de ML peuvent apprendre à reconnaître des patterns complexes dans des séries temporelles multi-dimensionnelles (données de capteurs) qui sont souvent imperceptibles à l'œil humain ou aux méthodes statistiques classiques. Pour la prédiction de la RUL, on utilise typiquement des **algorithmes de régression supervisée**. Le modèle apprend à partir d'exemples historiques où l'on connaît à la fois les mesures des capteurs et le temps effectif restant avant la panne. Une fois entraîné, il peut appliquer cette connaissance à de nouvelles données pour prédire une RUL future.

Comparaison des Stratégies : Corrective vs. Préventive vs. Prédictive :

Comparaison des approches de maintenance

Type	Principe	Avantages	Inconvénients
Corrective	Réparer après panne	Simple	Dangereux
Préventive	Remplacement à intervalles fixes	Sécurisé	Coûteux, gaspillage
Prédictive	Anticipation par IA	Optimal	Complexé

Explication Physique des Données :

Dataset NASA C-MAPSS :

Nous utilisons le dataset C-MAPSS (Commercial Modular Aero-Propulsion System Simulation) développé par la NASA, simulant la dégradation de 100 turboréacteurs sur 20631 cycles de fonctionnement. Chaque ligne contient : ID moteur, numéro de cycle, 3 paramètres opérationnels, et 21 capteurs mesurant températures, pressions, et vitesses de rotation.

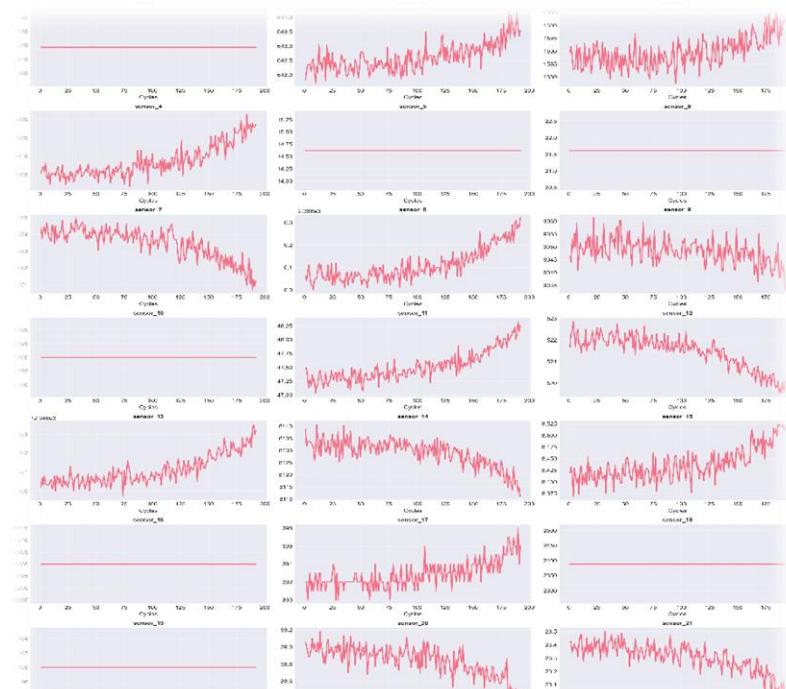
Mécanismes de dégradation :

Un turboréacteur se dégrade progressivement selon plusieurs mécanismes :

- **Erosion des pales** : Les pales du compresseur et de la turbine s'usent, réduisant l'efficacité aérodynamique
- **Encrassement** : Dépôts dans la chambre de combustion altérant la combustion
- **Fatigue thermomécanique** : Cycles thermiques répétés fragilisant les matériaux
- **Fuites** : Dégradation des joints entraînant des pertes de pression

Analyse des Capteurs Critiques :

La Figure 1 montre l'évolution des capteurs pour le moteur #1 au cours de ses 192 cycles.



Capteurs Réactifs (Informatifs) :

sensor 4 - Température T50 (sortie turbine) :

Observation : Augmentation progressive de +30°R sur 192 cycles.

Explication physique : Lorsque la turbine s'use, ses pales extraient moins d'énergie mécanique des gaz chauds. Ces gaz conservent donc une température plus élevée en sortie. Cette augmentation de la température EGT (*Exhaust Gas Temperature*) est un indicateur direct de la perte d'efficacité du moteur.

sensor 11 - Vitesse physique du fan :

Observation : Augmentation marquée après le cycle 100, passant de 47,0 à 48,5.

Explication physique : Pour compenser la perte d'efficacité du compresseur usé, le système de contrôle électronique augmente automatiquement la vitesse du fan afin de maintenir le débit d'air nécessaire. Cette surcompensation accélère l'usure (cercle vicieux) et constitue le signal le plus fort de dégradation.

sensor 12 - Vitesse corrigée du fan :

Observation : Diminution progressive.

Explication physique : La vitesse corrigée (ajustée selon les conditions atmosphériques) diminue car l'efficacité aérodynamique réelle du fan se dégrade, malgré l'augmentation de sa vitesse brute.

sensor 20 et sensor 21 - Ratios de pression :

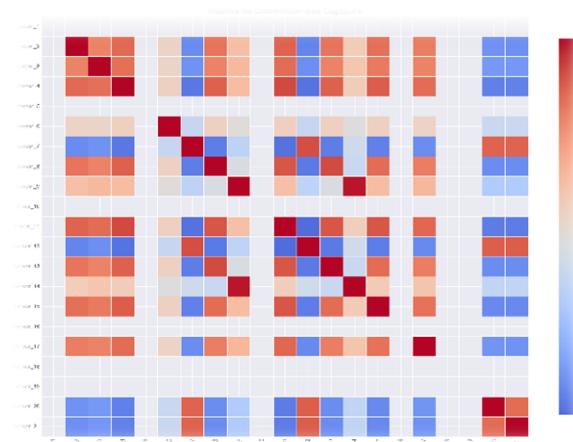
Observation : Décroissance linéaire.

Explication physique : L'usure du compresseur réduit sa capacité à augmenter la pression de l'air. Les ratios de compression diminuent, signalant une dégradation globale du système propulsif.

Capteurs Constants (Non Informatifs)

Sept capteurs restent parfaitement constants (écart-type < 0,01) : sensor 1, sensor 5, sensor 6, sensor 10, sensor 16, sensor 18, sensor 19. Ils mesurent probablement des paramètres fixes (altitude de croisière standard, pression de référence) et ne contiennent aucune information sur la dégradation du moteur.

Corrélation Entre Capteurs :



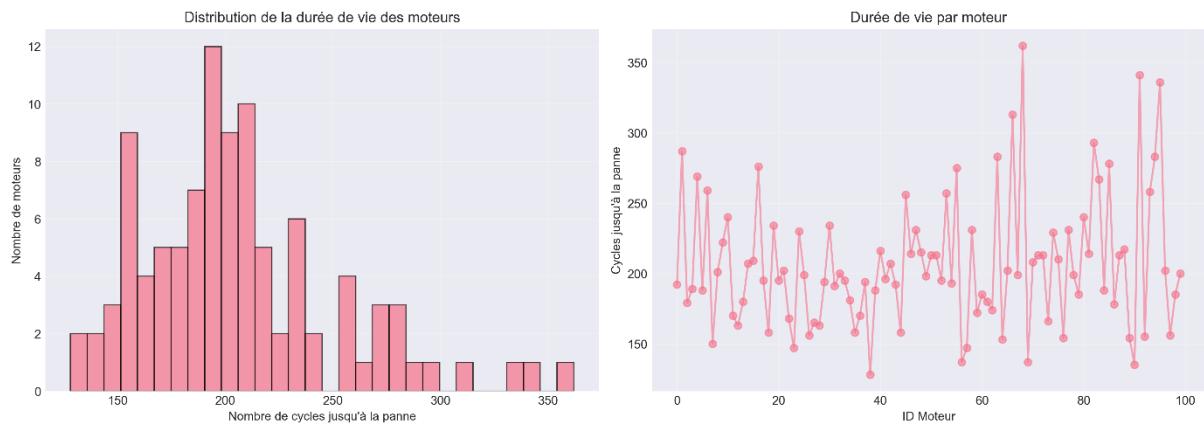
Matrice de corrélation révélant les couplages physiques.

Corrélations positives fortes : Les températures (sensor 2, 3, 4) évoluent ensemble, car elles mesurent le même flux thermodynamique à différents étages. De même, les pressions sont couplées par la loi des gaz parfaits.

Corrélation négative remarquable : sensor 11 (vitesse du fan) \leftrightarrow sensor 20/21 (ratios de pression) avec $r = -0,8$.

Interprétation : Quand le moteur force (vitesse \uparrow), les ratios de pression diminuent, ce qui confirme que le système compense la perte de performance.

Variabilité de la Durée de Vie :



Distribution de la durée de vie : forte variabilité (128 à 362 cycles).

Cette variabilité (facteur 2,8 entre moteurs) reflète la réalité opérationnelle : deux moteurs identiques connaissent des trajectoires de dégradation différentes selon leur historique (vols courts vs longs, conditions climatiques, maintenance).

Méthodologie de Nettoyage et Prétraitement

Étape 1 : Calcul de la Variable Cible (RUL) :

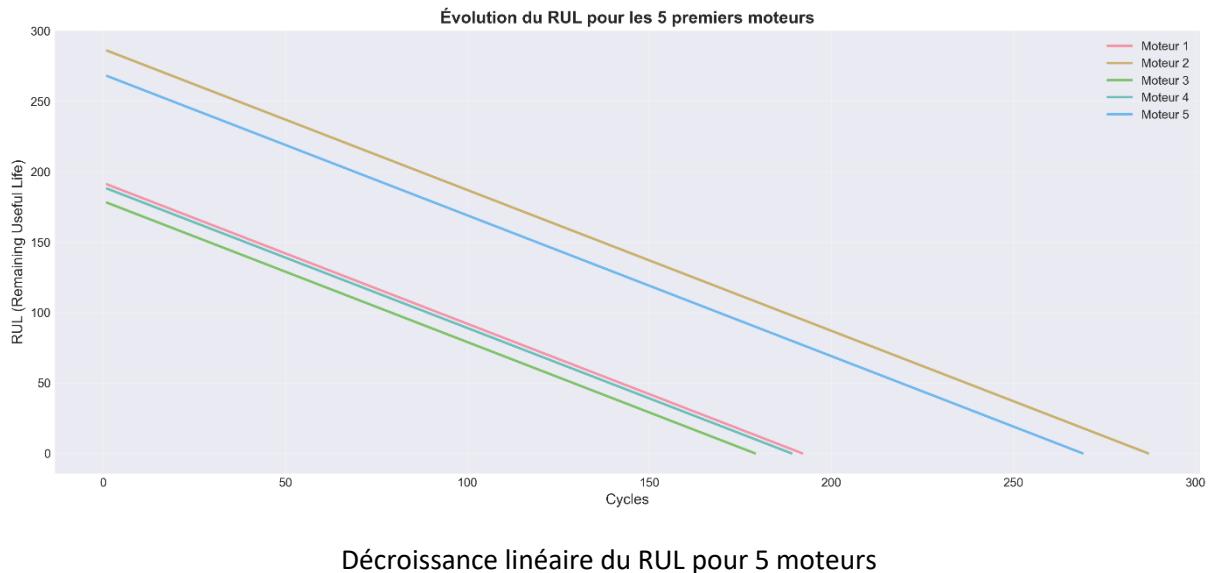
Le dataset brut ne contient pas la Durée de Vie Restante (RUL). Nous l'avons calculée pour chaque cycle selon la formule :

$$\text{RUL} = \text{cycle_max} - \text{cycle_actuel} \quad (1)$$

Où :

- **cycle_max** : Dernier cycle d'opération avant défaillance pour un moteur donné

- **cycle_actuel** : Cycle courant dans la séquence de vie du moteur
- **Exemple (Moteur #1, fin de vie au cycle 192) :**
- **Cycle 1** : RUL = $192 - 1 = 191$ cycles restants
- **Cycle 100** : RUL = $192 - 100 = 92$ cycles restants
- **Cycle 192** : RUL = 0 (défaillance)



Étape 2 : Suppression des Capteurs Constants

Critère : Écart-type < 0,01

Résultat : 7 capteurs supprimés (sensor 1, 5, 6, 10, 16, 18, 19), conservant ainsi 14 capteurs actifs + 3 paramètres opérationnels = **17 features au total.**

Justification : Un capteur constant n'apporte aucune information discriminante pour prédire le RUL. Le conserver ajouterait du bruit computationnel et ralentirait l'entraînement sans améliorer la précision du modèle.

Étape 3 : Normalisation Min-Max

Problème : Les capteurs présentent des échelles de mesure très différentes :

- Températures : 400-650 °R
- Pressions : 2-50 psi
- Vitesses : 2000-10000 RPM

Solution : Application d'une normalisation Min-Max ramenant toutes les valeurs dans l'intervalle [0, 1] :

$$X_{\text{norm}} = (X - X_{\text{min}}) / (X_{\text{max}} - X_{\text{min}}) \quad (\text{Équation 2})$$

Justification : Sans normalisation, les algorithmes de Machine Learning accorderaient un poids disproportionné aux variables de grande magnitude, biaisant ainsi les prédictions. Cette transformation garantit que chaque feature contribue équitablement à l'apprentissage.

Étape 4 : Division des Données (Train/Test)

- **Ensemble d'entraînement :** 80% des données (16 504 échantillons)
- **Ensemble de test :** 20% des données (4 127 échantillons)
- **Graine aléatoire :** `random_state = 42` (assure la reproductibilité des résultats)

Point crucial : Les variables `unit_nr` (identifiant moteur) et `time_cycles` ont été exclues des features d'entrée pour éviter toute fuite d'information (data leakage). Le modèle doit apprendre à prédire la RUL uniquement à partir de l'état physique des capteurs, non de la connaissance du temps écoulé.

Modélisation et Résultats

Modèles Testés

Trois modèles de complexité croissante ont été développés et comparés :

Modèle 1 : Régression Linéaire (Baseline)

Modèle de référence supposant une relation linéaire : $RUL = \beta_0 + \sum \beta_i \times \text{feature}_i$.

Avantages : Simplicité, rapidité d'entraînement (0,05 s).

Limites : Incapable de capturer les non-linéarités complexes de la dégradation.

Modèle 2 : Random Forest Regressor

Ensemble de 100 arbres de décision (bagging) dont les prédictions sont moyennées.

Hyperparamètres : `n_estimators=100, max_depth=20`.

Avantages : Capture les interactions complexes entre features, robuste au surapprentissage.

Modèle 3 : XGBoost Regressor

Algorithme de gradient boosting construisant séquentiellement 200 arbres, chacun corrigeant les erreurs résiduelles du précédent.

Hyperparamètres : `n_estimators=200, max_depth=8, learning_rate=0,1`.

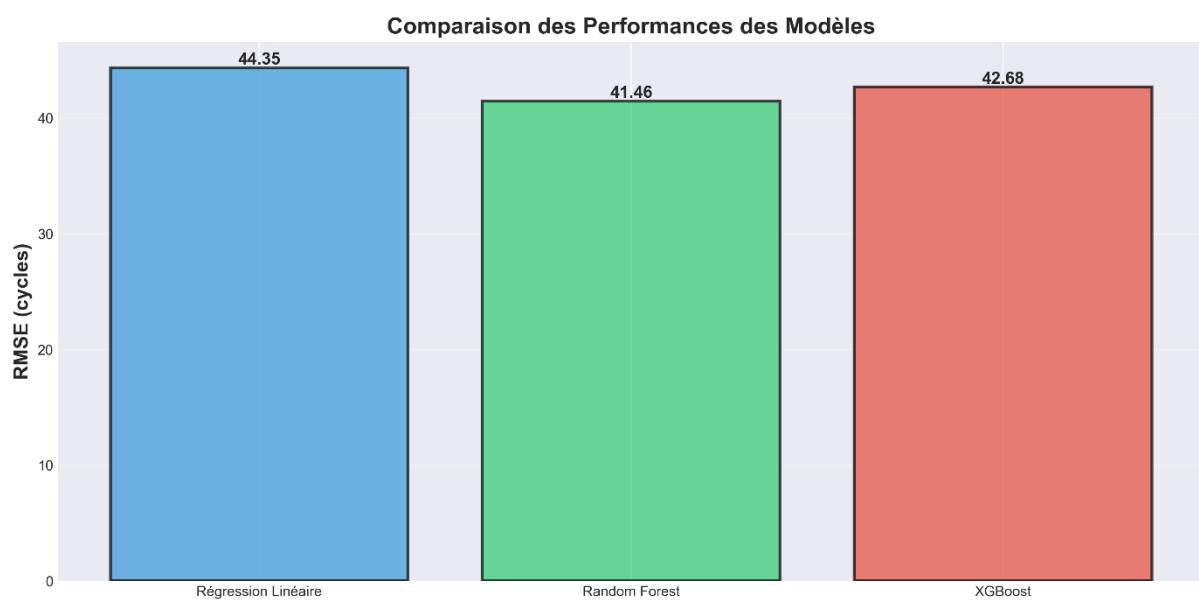
Tableau Comparatif des Performances

Comparaison des performances sur l'ensemble de test

Modèle	RMSE (cycles)	MAE (cycles)	R ² Score	Temps d'entraînement (s)
Régression Linéaire	44,35	34,07	0,5694	0,05
Random Forest	41,46	29,63	0,6237	2,3
XGBoost	42,68	30,31	0,6014	3,1

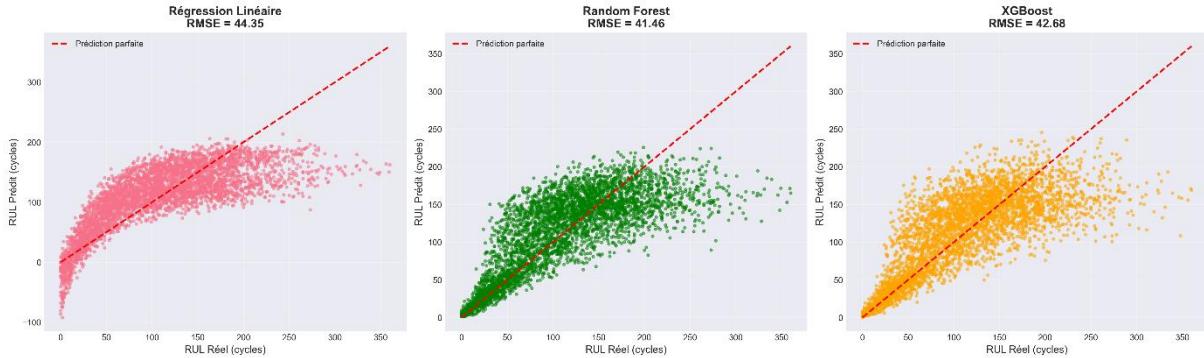
Légende des métriques :

- RMSE (Root Mean Square Error)** : Racine de l'erreur quadratique moyenne. Pénalise fortement les grandes erreurs, pertinente pour les applications critiques.
- MAE (Mean Absolute Error)** : Erreur absolue moyenne. Représente l'erreur moyenne en cycles.
- R² (Coefficient de détermination)** : Proportion de variance de la RUL expliquée par le modèle (0 à 1, où 1 indique une explication parfaite).



Meilleur modèle: Random Forest avec un RMSE de 41.46 cycles (amélioration de 6.5% vs régression linéaire).

Analyse des Prédictions



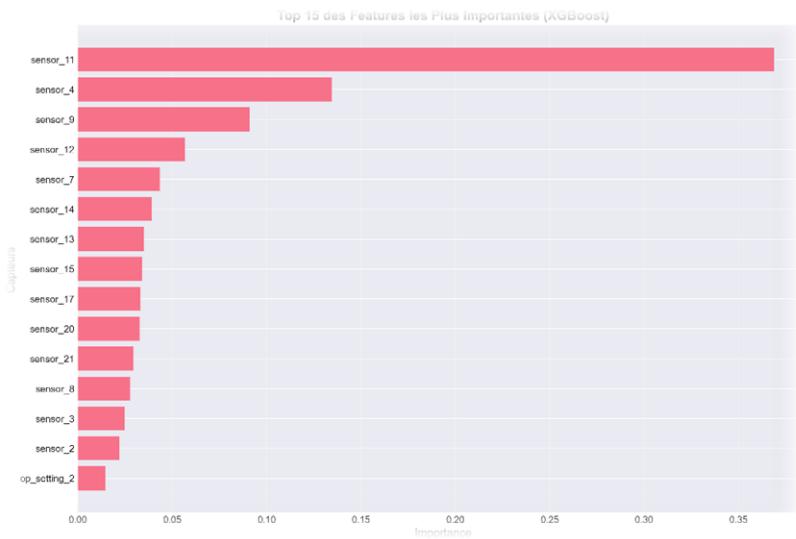
Prédictions vs valeurs réelles : Random Forest montre la meilleure concentration près de la diagonale (prédiction parfaite).

Observations :

- Régression Linéaire** : Forte dispersion, sous-estimation des RUL élevées.
- Random Forest** : Meilleure précision, quelques outliers persistent.
- XGBoost** : Performances similaires à Random Forest.

Outliers : Les erreurs > 100 cycles concernent les moteurs exceptionnels (durée > 300 cycles), cas rares sur lesquels le modèle, calibré sur des durées typiques (~200 cycles), échoue.

Importance des Capteurs



Capteurs les plus importants selon XGBoost

Top 3 des capteurs :

sensor 11 (37%) – Vitesse du fan : Indicateur de compensation mécanique.

sensor 4 (13%) – Température T50 : Perte d'efficacité thermodynamique.

sensor 9 (9%) – Pression : Fuites et pertes de charge.

Cohérence physique : Les capteurs identifiés comme importants par l'IA correspondent exactement à ceux montrant des dérives progressives dans la Figure 1.

Conclusion : Fiabilité de l'IA et Intégration en Avion Réel

Question Centrale : Peut-on Intégrer ce Système dans un Avion ?

Performances Actuelles

Critères aéronautiques :

- RMSE < 20 cycles → Excellent (déploiement possible)
- RMSE 20-30 cycles → Acceptable (validation approfondie requise)
- RMSE > 30 cycles → Insuffisant (R&D uniquement)

Notre résultat : RMSE = 41,46 cycles

Verdict : Les performances sont **INSUFFISANTES** pour une intégration directe en production.

Simulation de Risque

Scénario critique :

- Moteur réel : RUL = 15 cycles restants
- Prédiction du modèle : RUL = 56 cycles (erreur de +41 cycles)
- Conséquence : Le moteur tombe en panne 41 cycles avant l'intervention prévue
- Impact : Arrêt moteur en vol → Situation d'urgence

Risques Identifiés

Risque 1 : Erreurs Asymétriques

Impact selon le type d'erreur

Type d'Erreur	Conséquence	Gravité
Faux Négatif (Sous-estimation RUL)	Panne imprévue	CRITIQUE
Faux Positif (Sur-estimation RUL)	Maintenance prématuée	Acceptable (coût)

En aéronautique, un faux négatif peut mettre des vies en danger, alors qu'un faux positif ne coûte que de l'argent.

Risque 2 : Dominance Excessive d'un Seul Capteur

sensor 11 représente 37% de l'importance totale. Risques associés :

- **Single Point of Failure** : Une défaillance de ce capteur paralyse plus d'un tiers de la prédiction.
- **Vulnérabilité au bruit** : Erreur de mesure amplifiée.
- **Maintenance critique** : Ce capteur devient ultra-sensible.

Risque 3 : Moteurs Atypiques

Le modèle échoue sur les moteurs à durée de vie exceptionnelle (> 300 cycles), suggérant une calibration sur des cas "moyens" uniquement.

Risque 4 : Données Simulées

Le dataset C-MAPSS ne capture pas :

- Événements stochastiques (ingestion d'oiseaux, FOD)
- Variations climatiques extrêmes
- Qualité variable de la maintenance

Impact : Performances réelles probablement 20-30% inférieures.

Conditions d'Intégration Possible

L'intégration serait envisageable uniquement sous ces conditions strictes :

Conditions Techniques

Amélioration des performances : Atteindre RMSE < 20 cycles via :

- Feature engineering temporel (moyennes mobiles, tendances)
- Architecture hybride (XGBoost + LSTM)
- Optimisation hyperparamètres

Facteur de sécurité conservateur :

- Alerte maintenance si RUL prédit < 30 cycles
- Inspection obligatoire si RUL prédit < 15 cycles
- Immobilisation si RUL prédit < 5 cycles

Mode assistance décisionnelle (non autonome) :

- Le système alerte mais ne décide pas
- Validation humaine systématique par mécaniciens certifiés
- Double vérification via inspection visuelle

Redondance multi-capteurs :

- Développer un modèle moins dépendant de sensor 11
- Utiliser 5-6 capteurs avec importance équilibrée (15-20% chacun)

Conditions Réglementaires

Validation sur flotte réelle :

- Phase 1 (6 mois) : Tests sur données historiques

- Phase 2 (12 mois) : Déploiement en shadow mode (prédictions non utilisées)
- Phase 3 : Validation avec taux de faux négatifs < 0,01%

Certification DO-178C :

- Traçabilité complète du code
- Couverture de tests > 95%
- Documentation exhaustive
- Durée : 2-3 ans, Coût : 3-5 M€

Approbation EASA/FAA :

- Démonstration de la fiabilité statistique
- Plan de gestion des incidents
- Protocole de mise à jour du modèle

Recommandation Finale

VERDICT : Le système actuel **NE PEUT PAS** être intégré directement dans un avion en production.

UTILISATION POSSIBLE : Assistant décisionnel pour maintenance au sol, avec :

- Supervision humaine obligatoire
- Facteur de sécurité × 2 (diviser RUL prédit par 2)
- Validation par inspection physique

HORIZON : Intégration opérationnelle possible dans 2-3 ans après améliorations techniques et certification réglementaire.

Bénéfices Potentiels (Après Amélioration)

Si les performances atteignent le seuil requis (RMSE < 20 cycles) :

Économiques :

- Réduction coûts maintenance : 15-25%
- Amélioration disponibilité flotte : +10-15%
- ROI estimé : 18-24 mois

Environnementaux :

- Prolongation durée de vie moteurs : +15%
- Réduction gaspillage pièces : -30%
- Diminution consommation carburant : -2 à 3%

Sécurité :

- Détection précoce des défaillances
- Réduction pannes imprévues : -40%

Axes d'Amélioration Prioritaires

Pour atteindre un niveau de fiabilité acceptable :

Court terme (3-6 mois) :

- Corriger le split train/test (séparer par moteurs)
- Feature engineering temporel (tendances, moyennes mobiles)
- Optimiser hyperparamètres XGBoost

Moyen terme (6-18 mois) :

- Architecture LSTM pour capturer dépendances temporelles
- Ensemble XGBoost + LSTM + Random Forest
- Tests sur données réelles (partenariat Air France/Lufthansa)

Long terme (2-3 ans) :

- Jumeau numérique (Digital Twin)
- Intégration capteurs additionnels (vibrations, acoustique)
- Certification et déploiement industriel

Conclusion Générale

Ce projet a démontré la faisabilité technique d'une approche d'Intelligence Artificielle pour prédire la durée de vie des turboréacteurs, tout en révélant les défis considérables avant une application industrielle.

Résultats obtenus :

- RMSE de 41,46 cycles (Random Forest)
- Identification correcte des capteurs critiques
- Cohérence physique validée

Verdict d'intégration : Non immédiate, mais possible dans 2-3 ans après améliorations techniques et certification réglementaire. Le système actuel convient à une assistance décisionnelle au sol avec supervision humaine.

La maintenance prédictive représente l'avenir de l'aviation, conciliant sécurité, efficacité économique et durabilité environnementale. Notre travail pose les fondations d'un système prometteur nécessitant encore maturation avant déploiement opérationnel.